

Justificación del tamaño muestral y análisis de potencia estadística

Impartido por: *David López-García, Filip Andras y David Sánchez Casasola*

v.2026-02



cimcyc.ugr.es


 Brain, Mind and Behavior Research Center – CIMCYC

 @cimcyc.bsky.social

 cimcyc



UNIVERSIDAD
DE GRANADA



*Para casos más complejos (~~G*Power~~, ~~superpower~~) simulamos la “realidad”*

Scripts 1-7

Primero. Hay que tener una buena intuición de cómo se comportan nuestros datos y determinar el tamaño del efecto (*ej. las diferencias entre las condiciones/cómo van a mejorar los pacientes*).

¿Cómo lo hacemos?

Conocimiento previo, literatura, datos piloto, tamaño de efecto mínimo de interés/clínicamente significativo etc.


Segundo. Generamos datos sintéticos y realizamos nuestro test estadístico.

Script 8

¿Cuántos datos?

Para llegar a detectar los efectos que esperamos (*p-value* $< .05$) de forma repetida (potencia estadística alta/falsos negativos bajos).

¿Qué parte es más complicada?



1000x

Procesos cognitivos en el reconocimiento visual de las palabras

ruta léxica

Palabras frecuentes

gato



Análisis global de la palabra

ruta subléxica

Palabras poco
frecuentes, largas,
pseudopalabras

procrastinación

Procedimiento analítico de
conversión grafema-fonema



Coltheart et al. (2001)

Figure 6. Basic architecture of the dual-route cascaded model of visual word recognition and reading aloud.


Procesos cognitivos en el reconocimiento visual de las palabras

Tarea de decisión léxica: participantes tienen que decidir si lo que ven es una palabra real o una *pseudopalabra*

Lo que manipulamos: propiedades de las palabras reales como su *frecuencia léxica*

Alta frecuencia: creer, fuego, marrón, parir, etc.

Baja frecuencia: tarro, foca, gaita, fango, etc.



<https://exponline.ugr.es/publix/1164/start?batchId=1373&generalMultiple>

3.1 The final generative model

By the end of Part 7, we will be simulating reaction times from this **log-normal mixed-effects model**:

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 + u_{1i}) \times \text{cond.cod}_{ij} + \varepsilon_{ij}$$

with seven parameters:

- β_0 — grand mean on the log scale
- β_1 — the lexical-frequency effect
- u_{0i}, u_{1i} — by-subject adjustments to the intercept and the slope (correlated by ρ)
- w_{0j} — by-item adjustments to the intercept
- ε_{ij} — residual noise

And we will fit it with the corresponding `lmer()` call:

```
m <- lmer(log(rt) ~ cond.cod + (1 + cond.cod | subj) + (1 | item),
          data = sim_dat)
```

3.3 The power analysis itself

Once we have a generator and a model, we wrap them in **two nested for-loops** to estimate power across a grid of design choices:

```
for each (n_subjects, n_items) combination on the grid:
  for i in 1:nsim:
    generate one simulated dataset with these parameters
    fit lmer(log(rt) ~ cond.cod + (1 + cond.cod | subj) + (1 | item))
    extract the p-value for the condition effect
    power[this cell] = proportion of p-values below 0.05
```

The outer loop sweeps the design space; the inner loop is the Monte Carlo estimate of power at each cell. The output is a power table — for example:

3.2 What the simulated data look like





Figure 1: Simulated reaction times from the final model ($n = 100$ subjects, $k = 100$ items per condition). Each subject has their own mean RT and their own frequency-effect size; the red diamonds mark the grand means. This is what 'simulating from the final generative process' produces.

¿Cuántos datos debemos recoger?

Si el tamaño de efecto fuese pequeño... ¿qué combinación de participantes/ensayos es la óptima?

(SESOI, recursos disponibles)



R script 8.

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · ejemplo

Ejemplo: tarea de decisión léxica; identificar palabras de frecuencia léxica alta vs. baja; ej. ceder vs. claudicar

NUESTRA REALIDAD:

tiempos de respuesta = tiempo promedio + efecto de nuestra manipulación

β_0 "beta 0"
PARÁMETRO

↑
725 ms
intercepto

β_1 "beta 1"
PARÁMETRO

↑
+/- 25 ms (50 ms de diferencia)
pendiente

DEFINICIÓN:

Un parámetro es un valor numérico que define el modelo y que queremos estimar a partir de los datos.



¿Qué nos fastidia en conocer la realidad?

05 | Análisis de poder para diseños más complejos · *Simulación de datos*

¿Qué nos fastidia en conocer la realidad?


NUESTRA REALIDAD:

tiempos de respuesta = tiempo promedio + efecto de nuestra manipulación


β_0 "beta 0" PARÁMETRO β_1 "beta 1" PARÁMETRO

↑ 725 ms ↑ ± 25 ms (50 ms de diferencia)

PARÁMETRO
+ ruido





Lapsus de atención
Variabilidad en la respuesta motora
Fatiga
Distracciones



05 | Análisis de poder para diseños más complejos · *Simulación de datos*

SOLUCIÓN:

Recogemos más datos, el error residual se va aproximando a una distribución normal con media de 0 y su efecto en nuestras estimaciones se reduce.



¿Cuántos datos? Para que en 80/95% de los casos seamos capaces de detectar/estimar precisamente los parámetros que nos interesen.

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · Acercándonos a la realidad

Nuestra realidad es algo más compleja que esto:


R script 1.
entre-grupos

NUESTRA REALIDAD: 3 PARÁMETROS

intercepto (725 ms)

pendiente (50 ms) $\times$ (-0.5/+0.5)

error

$$rt = \beta_0 + (\beta_1 \times cond.cod) + \varepsilon$$


05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...


- | | |
|--|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes, que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · acercándonos a la realidad

2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos aleatorios por sujeto)



05 | Análisis de poder para diseños más complejos · *Simulación de datos* · acercándonos a la realidad

2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos aleatorios por sujeto)

NUESTRA REALIDAD: 4 PARÁMETROS


$$rt_i = \beta_0 + u_{0i} + (\beta_1 \times \text{cond. cod}) + \varepsilon$$


intercepto (725 ms)

pendiente (50 ms) $\times$ (-0.5/+0.5)

error

interceptos aleatorios por sujeto





05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...

- | | |
|--|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes, que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*


Nuestra realidad es más compleja...

- | | |
|--|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes, que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS



$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes varían entre sujetos)



4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes en las reacciones)

NUESTRA REALIDAD: 5 PARÁMETROS



05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...

- | | |
|--|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes, que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿ Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |



MODELO FINAL CON 7 PARÁMETROS

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times cond.cod + u_{1i}) + \varepsilon$$

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · acercándonos a la realidad

5. *Y ¿si los participantes que son más lentos, muestran efectos más pequeños? (la correlación entre los interceptos y las pendientes)* R script 5.

NUESTRA REALIDAD: 6 PARÁMETROS



05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...

- | | |
|---|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿ Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times cond.cod + u_{1i}) + \varepsilon$$

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · acercándonos a la realidad

6. ¿Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras)

R script 6.

NUESTRA REALIDAD: 7 PARÁMETROS

$$rt_i = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

Diagram illustrating the components of the mixed-effects model equation:

- β_0 : intercepto (725 ms)
- u_{0i} : interceptos aleatorios por ítem
- w_{0j} : interceptos aleatorios por sujeto
- β_1 : pendiente (50 ms) $\times$ (-0.5/+0.5)
- u_{1i} : pendientes aleatorias por sujeto
- ε : error

The terms u_{0i} and u_{1i} are grouped under the label "correlacionado" (correlated), indicating that the random intercepts and slopes for a given subject are correlated.

Alta frecuencia:

creer, fuego, marrón, parir, palo, salud, sofá

Baja frecuencia:

tarro, foca, forro, mosto, liebre, gaita, fango

Las palabras no son estímulos idénticos (como lo son las flechas en una tarea de flancos, por ejemplo)

tienen su propia variabilidad...

Además, diferentes sujetos responden al mismo estímulo, **no se trata de datos independientes:**

subj1	sofá
subj2	sofá
subj3	sofá
subj4	sofá
subj5	sofá

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...

- | | |
|---|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS


$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times cond.cod + u_{1i}) + \varepsilon$$

7 ¿Los tiempos de reacción, se distribuyen de forma normal


$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

Diagram illustrating the components of the mixed-effects model equation:

- β_0 : intercepto (6.59 log(ms))
- u_{0i} : interceptos aleatorios por ítem
- w_{0j} : interceptos aleatorios por sujeto
- $\beta_1 \times \text{cond.cod} + u_{1i}$: pendiente (0.10 log(ms) × (-0.5/+0.5))
- ε : error
- u_{1i} and ε are grouped as "pendientes aleatorios por sujeto" and "correlacionado".



R script 7.



Shiny app → <https://lindeloev.shinyapps.io/shiny-rt/>


¿Qué parámetros queremos estimar?

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$


Diagram illustrating the components of the mixed-effects model equation:

- β_0 : intercepto (6.59 log(ms)) ✓
- u_{0i} : interceptos aleatorios por sujeto
- w_{0j} : interceptos aleatorios por ítem
- β_1 : pendiente (0.10 log(ms)) × (-0.5/+0.5) ✓
- u_{1i} : pendientes aleatorios por sujeto
- ε : error


The model is also labeled as "correlacionado" (correlated).



$$w_{0j} \sim N(0, \sigma_{w0})$$



$$\varepsilon \sim N(0, \sigma)$$




$$\begin{pmatrix} u_0 \\ u_1 \end{pmatrix} \sim MVN \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma_u \right)$$

$$\Sigma_u = \begin{pmatrix} \sigma_{u0}^2 & \rho_u \sigma_{u0} \sigma_{u1} \\ \rho_u \sigma_{u0} \sigma_{u1} & \sigma_{u1}^2 \end{pmatrix}$$

05 | Análisis de poder para diseños más complejos · *Simulación de datos*

Ejemplo de un set de datos generados con 100 participantes y 100 ensayos por condición:

$$\log(rt_{ij}) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$



Random effects:

Groups	Name	Variance	Std.Dev.	Corr
item	(Intercept)	0.0097138	0.09856	
subj	(Intercept)	0.0555278	0.23564	
	cond.cod	0.0002061	0.01436	-0.58
Residual		0.0634124	0.25182	

Number of obs: 20000, groups: item, 200; subj, 100

Fixed effects:

	Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	6.56757	0.02464	116.44045	266.566	< 0.0000000000000002 ***
cond.cod	0.09825	0.01446	199.92015	6.796	0.000000000121 ***

¿Puedo replicar el efecto 80/95% de las veces? ¿Controlando el error Tipo II (falsos negativos)?

05 | Análisis de poder para diseños más complejos · *Simulación de datos* · *Acercándonos a la realidad*

Nuestra realidad es más compleja...

- | | |
|---|-------------|
| 2. ¿Podemos asumir que el tiempo basal es idéntico para todos los participantes? (interceptos) | R script 2. |
| 3. Los participantes responden a múltiples ensayos. | R script 3. |
| 4. ¿Podemos asumir que todos los sujetos van a reaccionar de forma igual a nuestra manipulación? (las pendientes) | R script 4. |
| 5. Y ¿si los participantes que son más lentos, muestran efectos más pequeños? (<u>la correlación</u> entre los interceptos y las pendientes) | R script 5. |
| 6. ¿ Existe variabilidad para los ítems (palabras), igual que entre los participantes? (interceptos para las palabras) | R script 6. |
| 7. ¿Los tiempos de reacción, se distribuyen de forma normal? | R script 7. |
| 8. ¿Cuántos datos (participantes/ensayos) debo recoger para detectar los efectos repetidamente (80/95%)? | R script 8. |

MODELO FINAL CON 7 PARÁMETROS

$$\log(rt_i) = \beta_0 + uo_i + wo_j + (\beta_1 \times cond.cod + u_{1i}) + \varepsilon$$

8. *¿Cuántos datos debemos recoger y para qué tamaños de efecto?*

R script 8.

BUCLE 2

Para posibles tamaños de efecto y posibles tamaños muestrales, repite:

BUCLE 1

PASO I. GENERACIÓN DE DATOS

$$\log(rt_i) = \beta_0 + u_{0i} + w_{0j} + (\beta_1 \times \text{cond.cod} + u_{1i}) + \varepsilon$$

PASO II. REALIZACIÓN DEL TEST, EXTRAEMOS P-VALUES

```
p-values <- lmer(log(rt) ~ 1 + cond.cod + (1 + cond.cod|subj) + (1|item))
```

PASO III. REALIZAMOS NUMEROSAS SIMULACIONES

PASO IV. CALCULAR LA POTENCIA

```
power <- (p-values < 0.05)/1000
```


simulaciones
1000

Tabla de potencias estadísticas

8. *¿Cuántos datos debemos recoger?*

R script 8.

¿Cuántos participantes
necesito para diferentes
tamaños de efecto?




Nota. 40 ensayos por condición

8. *¿Cuántos datos debemos recoger?*

Si el tamaño de efecto fuese pequeño... ¿qué combinación de participantes/ensayos es la óptima?

(SESOI, recursos disponibles)



R script 8.

Justificación del tamaño muestral y análisis de potencia estadística

Impartido por: *David López-García, Filip Andras y David Sánchez Casasola*

v.2026-01



cimcyc.ugr.es

 Brain, Mind and Behavior Research Center – CIMCYC

 @cimcyc.bsky.social

 cimcyc



UNIVERSIDAD
DE GRANADA

